

Informe final de PI

Integrantes:

- Ruiz Arias Alan Tomas
- Ruiz Arias Carol Beatriz

Sede: Nueva Esperanza

Objetivo: Identificar el perfil de los usuarios que generan mayor tiempo de visualización en la plataforma, para aportar información que permita diseñar estrategias de retención e incremento de ingresos.

Pregunta de investigación: ¿Qué características tienen los usuarios que consumen más tiempo de contenido en la plataforma?

Exploración y limpieza

En primer lugar, se llevó a cabo el proceso de exploración de los datos de la plataforma de streaming para saber su estructura y conformación, detectar los posibles errores e inconsistencias que podría tener para después poder realizar la limpieza y preparación del conjunto de datos para dejarlo listo para su análisis.

Los principales errores detectados en la exploración fueron:

- Algunas columnas con datos faltantes
- Existencia de datos duplicados
- Nombres de registros categóricos escritos de diversas maneras (requieren estandarización)
- Detección de valores irreales en edad, minutos de visualización y cantidad de tickets de soporte.
- Fechas futuras imposibles
- Espacios en blanco en las columnas de texto

Las principales actividades realizadas durante la limpieza fueron:

- Carga y visualización inicial del dataset.
- Se utiliza el (.copy) para conservar el dataset original antes de realizar la limpieza
- Traducción de los nombres de las variables del inglés al español para facilitar su interpretación.
- Eliminación de registros duplicados.
- Limpieza de espacios en blanco en las columnas de texto.
- Estandarización de los valores de los planes de suscripción, países y géneros favoritos para unificar diferentes formas de escritura.
- Conversión de la columna de fecha al tipo de dato correspondiente y eliminación de fechas futuras inválidas.
- Detección y corrección de valores fuera de rango en variables como edad, minutos de visualización y cantidad de tickets de soporte.
- Imputación de valores faltantes utilizando la mediana (para variables numéricas) y la moda (para variables categóricas).
- Verificación final de la calidad de los datos, comprobando la ausencia de valores nulos y registros duplicados.

- Cálculo del porcentaje de registros conservados tras el proceso de limpieza.
- Se registran todas actividades realizadas en un pipeline.csv.
- Finalmente, se exportan el dataset limpio y el crudo en archivos tipo json para su posterior análisis.

En conclusión, se implementa un proceso completo de preprocesamiento de datos, mejorando la calidad, consistencia y confiabilidad del conjunto de datos antes de realizar el análisis.

Análisis del dataset procesado

Se realizaron diversos graficos para inferir relaciones entre las diversas variables:

- Histograma de distribución de cantidad de usuarios por tiempo de visualización
- Histograma de cantidad de usuarios por plan
- Histograma de promedio de minutos de visualización por plan
- Gráfico de dispersión de minutos de visualización por edad
- Histograma de genero favorito por minutos de visualización promedio
- Gráfico de dispersión de edad, plan y tiempo de visualización.

Conclusión del EDA: En base a la evidencia recolectada, los usuarios que consumen más tiempo de contenido en la plataforma tienden a ubicarse en un rango etario de 15 a 60 años y muestran mayor probabilidad de pertenecer a planes de suscripción superiores, aunque el alto consumo también se manifiesta de forma significativa en usuarios de planes económicos. Esto indica que el comportamiento de consumo elevado responde a un patrón de uso que no está determinado exclusivamente por el plan contratado, lo que abre una oportunidad concreta de negocio: identificar y convertir a los usuarios de planes básicos que ya presentan un consumo equivalente al de usuarios premium.

Exploración de componentes principales (PCA)

- Evidencia: El análisis de PCA sobre las variables edad, minutos de visualización y tickets de soporte al cliente mostró que se requieren los tres componentes para explicar aproximadamente el 100% de la varianza, sin una reducción significativa de dimensionalidad. Los loadings mostraron que CP1 contrapone consumo de contenido y tickets de soporte, CP2 está dominado por la edad, y CP3 combina las tres variables.

- Interpretación: La baja correlación entre las variables originales impide que el PCA concentre la varianza en pocos componentes, aunque permitió identificar una posible asociación inversa entre tiempo de consumo y cantidad de tickets de soporte.

- Conclusión: El PCA no resultó eficaz como técnica de reducción de dimensionalidad para este dataset, pero aportó valor exploratorio al sugerir que el consumo elevado podría estar asociado a una menor cantidad de reclamos de soporte, una relación que podría profundizarse en análisis posteriores.

Limitaciones

El alcance de las conclusiones se encuentra condicionado por las variables disponibles en el dataset (edad, plan, minutos de visualización, tickets de soporte), que no permiten explicar completamente la variabilidad del comportamiento de consumo. El análisis fue de carácter exploratorio y descriptivo; las relaciones identificadas entre variables no fueron validadas mediante pruebas estadísticas de significancia ni modelos predictivos. El PCA aplicado no logró

reducir efectivamente la dimensionalidad del conjunto de datos, dado el bajo nivel de correlación lineal entre las variables numéricas disponibles.

Mejoras futuras

Una mejora futura podría consistir en incorporar variables adicionales (dispositivo de acceso, género de contenido preferido, antigüedad como usuario) que permitan enriquecer el perfil del usuario de alto consumo. Se propone como siguiente etapa el desarrollo de un modelo de clasificación supervisada que permita predecir la probabilidad de que un usuario pertenezca al segmento de alto consumo a partir de las variables identificadas como relevantes durante el análisis exploratorio. Sería recomendable explorar con mayor profundidad la relación entre tiempo de consumo y tickets de soporte identificada en el PCA, dado su potencial valor para estrategias de retención.